

Θεωρία Αποφάσεων

ΕΡΓΑΣΙΑ 1

2024-2025

Μαύρα Πολυδώρου ΑΜ:1064885

Γενικά

- **Σύμβολο Μετοχής** : NVDA - NVIDIA Corporation
- Στο φάκελο επισυνάπτεται και ο κώδικας
- Οι μετρικές που χρησιμοποιήθηκαν για την αξιολόγηση τόσο του γραμμικού όσο και του πολυωνυμικού μοντέλου παλινδρόμησης είναι οι εξής:

1. **MSE (Mean Squared Error)** που μετρά τη μέση τετραγωνική απόκλιση μεταξύ των πραγματικών τιμών και των προβλεπόμενων τιμών
2. **(MAE) Mean Absolute Error** που είναι η μέση διαφορά ανάμεσα στις πραγματικές τιμές και στις προβλεπόμενες τιμές

Ερώτημα Α

- Το σύνολο επικύρωσης ορίστηκε σε όλο το έτος του 2024 σύμφωνα και με τις οδηγίες της εκφώνησης. Έγιναν δοκιμές για μικρότερο σύνολο μέσα στο 2024 αλλά όλο το έτος είχε τα καλύτερα αποτελέσματα
- Ομοίως έγιναν παραπάνω δοκιμές από όσες παρουσιάζονται παρακάτω αλλά επισημαίνονται αυτές που είχαν την μεγαλύτερη διακύμανση μεταξύ των μετρικών

Αφού ολοκληρώθηκαν τα βήματα σύμφωνα με την εκφώνηση

- ανάκτηση δεδομένων
- χαρακτηριστικά καθυστέρησης
- επεξεργασία τιμών με Gaussian φίλτρο
- διαχωρισμός συνόλου εκπαίδευσης-επικύρωσης

δημιουργήθηκε το γραμμικό μοντέλο παλινδρόμησης.

Αρχικά, κατά την συγγραφή του κώδικα οι ενδεικτικές τιμές που δόθηκαν στην παράμετρο εξομάλυνσης του Gaussian φίλτρου (**sigma**) ήταν **1** και ο αριθμός των lag features (**N**) ήταν **2**.

Οπότε σε πρώτο επίπεδο κρατήθηκαν αυτές οι τιμές και έγιναν δοκιμές στα χρονικά όρια του συνόλου εκπαίδευσης και επικύρωσης.

Το σύνολο εκπαίδευσης αρχικά ορίστηκε στο πλαίσιο μιας 10ετίας ενώ στο validation data εισήχθη όλο το έτος του 2024 και συγκεκριμένα αυτές οι ημερομηνίες:

- `start_date_train = '2012-11-03'`
`end_date_train = '2022-12-31'`
- `start_date_val = '2024-10-03'`
`end_date_val = '2024-11-19'`

Τα αποτελέσματα φαίνονται παρακάτω :

- **Intercept:**
0.26981178454488486
- **Coefficients:**[1.79614195
-0.79769757]
- **MSE (Training Data):** 16.507867842780126
MAE (Training Data): 1.365314510152041
- **MSE (Validation Data):** 1.181185060275823
MAE (Validation Data): 0.9692492853356368

Παρατηρήθηκε ότι υπάρχει μια υψηλή διαφορά στο MSE του συνόλου εκπαίδευσης και επικύρωσης, το οποίο μπορεί να δηλώνει υπερπροσαρμογή του μοντέλου δηλαδή το μοντέλο είναι αρκετά σύνθετο και δεν έχει εκπαιδευτεί σωστά. Συγκεκριμένα όσον αφορά το σύνολο εκπαίδευσης φαίνεται το μοντέλο να έχει μια μεγάλη απόκλιση στις προβλέψεις σε σχέση με τις πραγματικές τιμές. Αντίθετα αν παρατηρήσουμε το σύνολο επικύρωσης το μέσο τετραγωνικό σφάλμα είναι αρκετά χαμηλό και άρα έχει αρκετή ακρίβεια σε νέα δεδομένα.

Αντίθετα το MAE είναι αρκετά χαμηλό στα δεδομένα εκπαίδευσης παραμένει όμως μεγαλύτερο από τα δεδομένα επικύρωσης. Η μεγάλη διαφορά του σε σχέση με το MSE οφείλεται στο ότι το μέσο τετραγωνικό σφάλμα επηρεάζεται περισσότερο από ορισμένα λάθη στις προβλέψεις την στιγμή που το απόλυτο σφάλμα προσφέρει μια πιο γενική εικόνα της εκπαίδευσης του μοντέλου.

Επίσης ξανά το μοντέλο κάνει αρκετά καλές προβλέψεις στα νέα δεδομένα.

Το γενικό συμπέρασμα είναι ότι το μοντέλο αυτό δεν έχει εκπαιδευτεί καλά με τα δεδομένα που έχουν δοθεί μέχρι στιγμής και υπάρχει μια μεγάλη απόκλιση στις μετρικές σφάλματος σε σχέση με τα δεδομένα επικύρωσης, όπου εκεί η πρόβλεψη είναι πολύ καλύτερη.

Στη συνέχεια δόθηκαν για εκπαίδευση οι τιμές κλεισίματος της μετοχής για μια 20ετία με τα παρακάτω αποτελέσματα.

- `start_date_train = '2002-11-03'`
`end_date_train = '2022-12-31'`
- `start_date_val = '2024-10-03'`
`end_date_val = '2024-11-19'`
- **Intercept:**
0.10864607316851504
- **Coefficients:**[1.79636511
-0.7974637]
- **MSE (Training Data):** 8.382745362649908
MAE (Training Data): 0.7639596497798344
- **MSE (Validation Data):** 1.2143277470821057
MAE (Validation Data): 0.9726310239947902

Με αυτό το σύνολο εκπαίδευσης και επικύρωσης υπάρχει μια μεγάλη βελτίωση στις μετρικές σφάλματος και έτσι φαίνεται πως το μοντέλο έχει εκπαιδευτεί καλύτερα και έχει καλύτερη εφαρμογή στο σύνολο εκπαίδευσης. Να τονιστεί εδώ ότι υπάρχει μια μικρή διαφορά σε σχέση με τα προηγούμενα αποτελέσματα και εδώ το MAE είναι υψηλότερο στο σύνολο επικύρωσης σε σχέση με το εκπαίδευσης, όμως παραμένουν στα ίδια επίπεδα και άρα φαίνεται ότι αποδίδει καλύτερα.

Τέλος εφόσον και οι χρονολογίες ήταν αρκετά κοντά το σύνολο εκπαίδευσης που δοκιμάστηκε και κρατήθηκε εν τέλει ήταν από την αρχή (χρονολογικά) των στοιχείων που υπήρχαν στο csv αρχείο και συγκεκριμένα,

- `start_date_train = '1999-11-03'`
`end_date_train = '2023-12-31'`
- `start_date_val = '2024-10-03'`
`end_date_val = '2024-11-19'`

- **Intercept:**
0.10322021660107339
- **Coefficients:**[1.79559087
-0.7964674]
- **MSE (Training Data):** 7.903763128738895
MAE (Training Data): 0.7929184811761341
- **MSE (Validation Data):** 1.206176037001773
MAE (Validation Data): 0.973008673319936

Ξανά υπάρχει μια διαφορά στα αποτελέσματα των μετρικών όχι τόσο μεγάλη όσο πριν αλλά το μοντέλο φαίνεται να έχει εκπαιδευτεί καλύτερα με το συγκεκριμένο σύνολο εκπαίδευσης και η απόκλιση τόσο σε σύγκριση με τις πραγματικές τιμές κλεισίματος όσο και με τα νέα δεδομένα είναι αρκετά μικρή. Παρατηρούμε ξανά την διαφορά που οφείλεται σε ορισμένα σφάλματα και επηρεάζει το MSE πολύ περισσότερο όμως η μέση απόκλιση όπως δείχνει το MAE είναι σχετικά μικρή.

Αφού οριστικοποιήθηκε το χρονολογικό όριο στα δεδομένα εκπαίδευσης και επικύρωσης, δοκιμάστηκαν διαφορετικά νούμερα στις παραμέτρους εξομάλυνσης του Gaussian φίλτρου (sigma) και του αριθμού των lag features (N).

Αναλυτικότερα, για **sigma**=2 και **N**=2

- start_date_train = '1999-11-03'
end_date_train = '2022-12-31'
- start_date_val = '2024-10-03'
end_date_val = '2024-11-19'
- **Intercept:**
0.060547480168196444
- **Coefficients:**[1.94532257
-0.94599037]
- **MSE** (Training Data): 1.202588197894835
MAE (Training Data): 0.3326854498557751
- **MSE** (Validation Data): 0.20074974648430408
MAE (Validation Data): 0.37602409658935526

Τα νέα αποτελέσματα δείχνουν μια μεγάλη διαφορά στις μετρικές σφάλματος, οι οποίες τόσο για το σύνολο εκπαίδευσης όσο και για το σύνολο επικύρωσης προσεγγίζουν το 0.

Εδώ η διαφορά είναι μικρότερη και καταλαβαίνουμε ότι ότι τα σφάλματα είναι γενικά μικρά και δεν υπάρχουν τόσο μεγάλες αποκλίσεις που να επηρεάζουν πολύ το μοντέλο

Είναι λοιπόν εμφανές ότι όσο μειώνεται ο θόρυβος των δεδομένων το μοντέλο εκπαιδεύεται ακόμα καλύτερα σύμφωνα με τα δεδομένα που του δίνονται και η απόκλιση γίνεται ακόμα μικρότερη.

Την ίδια στιγμή οι παράμετροι του μοντέλου παραμένουν στα ίδια επίπεδα.

Τέλος, υπήρξε ένας ακόμα πειραματισμός με την παράμετρο εξομάλυνσης όπου για $\sigma=2$

και

- `start_date_train = '1999-11-03'`
`end_date_train = '2022-12-31'`
- `start_date_val = '2024-10-03'`
`end_date_val = '2024-11-19'`

τα αποτελέσματα είναι:

- **Intercept:**
0.04210794808986407
- **Coefficients:**[1.97396415
-0.97443272]



- **MSE** (Training Data): 0.39829931968045046
MAE (Training Data): 0.1921868180429103
- **MSE** (Validation Data): 0.05130748190303104
MAE (Validation Data): 0.1752311628859782

Με αυτές τις αλλαγές έχουμε τα καλύτερα αποτελέσματα στις μετρικές αξιολόγησης του μοντέλου. Φαίνεται πολύ καλά εκπαιδευμένο στα δεδομένα και οι παράμετροι δεν έχουν αυξηθεί πολύ.

Ενδιάμεσα έγιναν κάποιοι επιπλέον πειραματισμοί με τα N , σ όμως παρατηρήθηκε μεγάλη αύξηση των παραμέτρων του μοντέλου
πχ.

- **Intercept:** 0.012761127709495668
- **Coefficients:** [3.52613703 -4.90377965
3.21188856 -0.83438419]
- **MSE** (Training Data): 0.07734761814597539
MAE (Training Data): 0.08619480553475309
- **MSE** (Validation Data): 0.6738376081079983
MAE (Validation Data): 0.07976553258060987

Τα τελικά γραφήματα του γραμμικού μοντέλου φαίνονται παρακάτω:



Ερώτημα Β

Όσον αφορά το πολυωνυμικό μοντέλο που ζητήθηκε σε αυτό το ερώτημα

- κρατήθηκε το ίδιο σύνολο εκπαίδευσης και επικύρωσης
- δημιουργήθηκαν τα πολυωνυμικά χαρακτηριστικά του μοντέλου και εφαρμόστηκε γραμμική παλινδρόμηση πάνω σε αυτά
- στην συνέχεια ορίστηκαν οι υπερπαραμέτροι σύμφωνα με τις οποίες εκπαιδεύτηκε το μοντέλο και
- όπως ζητήθηκε απο την εκφώνηση εφαρμόστηκε κανονικοποίηση L1-L2
- Όσον αφορά την υπερπαραμέτρο l1-ratio που αφορά το επίπεδο της κανονικοποίησης κρατήθηκε στο 0,5 δηλαδή μεταξύ του 0 που βασίζεται αποκλειστικά στην l2 κανονικοποίηση (για μείωση των συντελεστών παραμέτρων του μοντέλου) ενώ όταν είναι 1 βασίζεται αποκλειστικά στην l1 κανονικοποίηση (για ενδεχόμενο μηδενισμό των συντελεστών παραμέτρων του μοντέλου)

- Οποιαδήποτε απόπειρα έγινε κοντά σε αυτή την τιμή και αποφεύγοντας τα 2 άκρα της υπερπαραμέτρου l1-ratio ώστε να εφαρμόζεται κανονικοποίηση και απο τις δυο νόρμες είχε μικρή επίδραση στις μετρικές σφάλματος οπότε κρατήθηκε το 0,5 που είχε τα καλύτερα αποτελέσματα

πχ.

για l1_ratio = 0.7

- **Intercept:** -0.05537854382033913
- **Coefficients:**
 - 1: 0.0
 - close_t-1_smoothed: 1.216141307886929
 - close_t-2_smoothed: -0.21376657923901762
 - close_t-1_smoothed^2: 0.0006946191322464351
 - close_t-1_smoothed close_t-2_smoothed :
-0.0003338169182910457
 - close_t-2_smoothed^2:
-0.00036664408232325494
- **MAE (Training Data):** 0.41622314442339253
- **MSE (Training Data):** 0.8804803100586049

Όλα τα παραπάνω αποτελέσματα δείχνουν ένα καλά εκπαιδευμένο μοντέλο τόσο για το σύνολο εκπαίδευσης όσο και για το σύνολο επικύρωσης με μικρές αποκλίσεις μεταξύ τους.


Όποτε έγινε μια τελική δοκιμή με τον βαθμό του πολυωνύμου σε degree=3, όπου και είχε τα καλύτερα αποτελέσματα


για **degree=3** και **alpha=0.1** , **l1_ratio=0.5**

- **Intercept:** 0.06057218809141318
- **Coefficients:**
 - 1: 0.0
 - close_t-1_smoothed: 1.1165477757032412
 - close_t-2_smoothed: -0.11865406853740897
 - close_t-1_smoothed^2: 0.0003763668819803299
 - close_t-1_smoothed close_t-2_smoothed: -0.00017125870261829954
 - close_t-2_smoothed^2: -0.0001891851280708842
 - close_t-1_smoothed^3: 7.085264016680265e-07
 - close_t-1_smoothed^2 close_t-2_smoothed: -2.212081119972043e-07
 - close_t-1_smoothed close_t-2_smoothed^2: -2.4317743473821954e-07
 - close_t-2_smoothed^3: -2.677448359282073e-07

- **MAE** (Training Data): 0.46408582680343635
MSE (Training Data): 0.9634846550827213
- **MAE** (Validation Data): 0.15551702022126832
MSE (Validation Data): 0.0415493634804133

Τα τελικά γραφήματα για αυτό το μοντέλο είναι τα παρακάτω





Όπως διαπιστώνουμε από τα αποτελέσματα των μετρικών και από τα διαγράμματα, πρόκειται για ένα μοντέλο με αρκετά καλή απόδοση.

Όσον αφορά το σύνολο επικύρωσης όπου βλέπουμε και τις μικρότερες τιμές για τα σφάλματα, συμπεραίνουμε ότι το μοντέλο γενικεύει αρκετά καλά στα νέα δεδομένα και για το σύνολο εκπαίδευσης αν και η απόκλιση στις τιμές δεν είναι μεγάλη σύμφωνα με το MAE, η υψηλότερη τιμή του MSE όμως υποδηλώνει ότι ενδεχομένως επειδή οι γραμμικές σχέσεις των συντελεστών δεν είναι οι βέλτιστες υπάρχουν και μεγαλύτερα σφάλματα στο μοντέλο.