

Θεωρία Αποφάσεων

ΕΡΓΑΣΙΑ 2

2024-2025

Μαύρα Πολυδώρου ΑΜ:1064885

Γενικά

- Για τον διαχωρισμό των σετ εκπαίδευσης-επικύρωσης-τεστ χρησιμοποιήθηκε η συνάρτηση `train_test_split()` η οποία χωρίζει το σύνολο σε train-test. Όμως, καθώς έχει ζητηθεί η αναλογία 60% για εκπαίδευση, 20% για validation, 20% για τεστ, η συνάρτηση χρησιμοποιήθηκε 2 φορές.

-την 1η έγινε διαχωρισμός σε 60% train-40% temporary set

-την 2η έγινε διαχωρισμός του temporary set σε 20%validation-20% test

Αυτή η διαδικασία πραγματοποιήθηκε και για τις δυο κατηγορίες(0-1), οπότε έγινε συνένωση των επιμέρους σετ για το τελικό σύνολο εκπαίδευσης.

Επίσης έγινε συνένωση των temporary data και στην συνέχεια έγινε ο διαχωρισμός 20%-20% με την συνάρτηση `train_test_split()`

- Το dataset που δόθηκε περιέχει 4 χαρακτηριστικά (variance, skewness, curtosis, entropy) και την κλάση (0-1).

Παρατηρώντας τις τιμές αυτών των χαρακτηριστικών φαίνεται μια μεγάλη διακύμανση μεταξύ αυτών, γεγονός που μπορεί να επηρεάσει την ταξινόμηση στην πορεία. Ορισμένα χαρακτηριστικά έχουν και αρνητικές τιμές μεταξύ -13 έως 12 για παράδειγμα.

Παρατηρώντας τις τιμές αυτών των χαρακτηριστικών φαίνεται μια μεγάλη διακύμανση μεταξύ αυτών, γεγονός που μπορεί να επηρεάσει την ταξινόμηση στην πορεία. Ορισμένα χαρακτηριστικά έχουν και αρνητικές τιμές μεταξύ -13 έως 12 για παράδειγμα.

Για αυτό το λόγο έγινε κανονικοποίηση των δεδομένων πριν την μέθοδο PCA ώστε να έχουν κοινή κλίμακα και να μην αλλοιωθεί το αποτέλεσμα και τα μοντέλα στη συνέχεια να έχουν μεγαλύτερη ακρίβεια.


Με βάση τις μεθόδους ταξινόμησης που ζητούνται στη συνέχεια της εκφώνησης (SVM, PCA, k-NN) η κανονικοποίηση έγινε με χρήση του `StandardScale()`, όπου τα δεδομένα κανονικοποιούνται ώστε:

- Ο μέσος όρος κάθε χαρακτηριστικού να είναι 0.
- Η τυπική απόκλιση κάθε χαρακτηριστικού να είναι 1

- Στα ερωτήματα έχει δημιουργηθεί διάγραμμα για το F1-score που ο υπολογισμός του ζητείται από την εκφώνηση. Η μετρική αυτή αξιολογεί το μοντέλο ταξινόμησης με βάση την ακρίβεια και ανάκληση και τα διαγράμματα δημιουργήθηκαν για καλύτερη οπτικοποίηση και κατ'επέκταση καλύτερη αξιολόγηση του μοντέλου και των αποτελεσμάτων.

Ερώτημα 1

Εφαρμόστηκε η μέθοδος PCA για μείωση των χαρακτηριστικών στα 2 όπως ζητήθηκε, και δημιουργήθηκε διάγραμμα όπως φαίνεται παρακάτω για την οπτικοποίηση του αποτελέσματος.




Στο διάγραμμα απεικονίζονται τα δεδομένα μετά την εφαρμογή PCA και τη μείωση των χαρακτηριστικών σε 2 συνιστώσες. Τα σημεία είναι χωρισμένα στις 2 κλάσεις 0(μπλε)-1(πορτοκαλί).

Φαίνεται ότι υπάρχει κάποιος διαχωρισμός μεταξύ των δύο κλάσεων, όχι πλήρης με την κόκκινη να είναι περισσότερο διασκορπισμένη οπότε και υπάρχουν αρκετά σημεία στα οποία οι 2 κατηγορίες συγχέονται

Στη συνέχεια έγινε ταξινόμηση με την χρήση των διαφορετικών παραθύρων Gauss στα παράθυρα Parzen.

Τα αποτελέσματα φαίνονται παρακάτω

- για bandwidths = [0.1, 0.5, 1.0, 2.0]



	Bandwidth	F1 Score
0	0.05	0.846082
1	0.10	0.864489
2	0.20	0.853220
3	0.30	0.802557
4	0.50	0.772788
5	0.75	0.779516
6	1.00	0.753058
7	1.50	0.731638
8	2.00	0.704874
9	3.00	0.610140

Την καλύτερη απόδοση την έχει το bandwidth 0,1-02, ενώ την χειρότερη απόδοση την έχει η τιμή 3. Δηλαδή στις χαμηλές τιμές bandwidth το F1-score είναι υψηλό και μειώνεται με την αύξηση του bandwidth.

Πιο συγκεκριμένα για τιμές bandwidth < 0.5 η ταξινόμηση είναι πολύ καλή, δηλαδή όταν το μοντέλο περιορίζεται στα κοντινά του σημεία και τα παράθυρα είναι στενά, το μοντέλο μπορεί να


Για bandwidth > 0.5 , το F1 Score μειώνεται σταδιακά και το μοντέλο αρχίζει να γενικεύει και δεν αποδίδει τόσο καλά, καθώς επηρεάζεται από περισσότερα δεδομένα γύρω από το σημείο ταξινόμησης και άρα δεν υπάρχει καλή διάκριση στις κλάσεις.

Τέλος για bandwidth > 2.0 παρατηρείται μεγάλη πτώση του F1 Score το μοντέλο δεν είναι ικανό να διακρίνει σωστά τις κατηγορίες, ενδεχομένως γιατί υπάρχει απώλεια στην πληροφορία γύρω από το σημείο ταξινόμησης.

Ερώτημα 2

Η ταξινόμηση σε αυτό το ερώτημα έγινε με την μέθοδο k-NN για διάφορες τιμές του k και τα αποτελέσματα φαίνονται παρακάτω.

- για $k_val = [1, 3, 5, 7, 9, 11, 15, 20, 25, 30, 50, 80, 100]$



Η βέλτιστη τιμή για το F1-score παρατηρείται στις τιμές κοντά στο 5 και το μέγιστο F1 Score εμφανίζεται στο $k = 5$. Δηλαδή για $k=5$ δηλαδή στους 5 πλησιέστερους γείτονες υπάρχει η καλύτερη ταξινόμηση.

Για πιο μικρά k (π.χ. 1, 3) το F1 Score παραμένει υψηλό αλλά δεν είναι πολύ σταθερό και μεταβάλλεται απότομα. Για μεγάλα k (π.χ. 50, 80, 100), το F1 Score είναι χαμηλό και αυτό γιατί το μοντέλο έχει περισσότερους γείτονες και η τελική απόφαση βασίζεται σε πιο γενικευμένα δεδομένα άρα χάνεται η διάκριση των κλάσεων.

Ερώτημα 3

Η ταξινόμηση σε αυτό το ερώτημα έγινε με γραμμικό και μη-γραμμικό SVM. Συγκεκριμένα, οι πυρήνες που χρησιμοποιήθηκαν ο γραμμικός πυρήνας και ο $\text{rbf}(\text{Gaussian})$, ενώ δοκιμάστηκε και ο πολυωνυμικός όμως τα αποτελέσματα του στο F1-score ήταν μικρότερα από τον rbf όπως φαίνεται παρακάτω και για αυτό κρατήθηκε ο rbf .

- για $c_val = [0.01, 0.05, 0.1, 0.5, 1, 5, 10, 20, 50, 100, 200]$

- για όλους τους πυρήνες

	Kernel	C	F1 Score
0	linear	0.01	0.725658
1	linear	0.05	0.715897
2	linear	0.10	0.715897
3	linear	0.50	0.719335
4	linear	1.00	0.715897
5	linear	5.00	0.715897
6	linear	10.00	0.715897
7	linear	20.00	0.715897
8	linear	50.00	0.715897
9	linear	200.00	0.715897
10	linear	100.00	0.715897

	Kernel	C	F1 Score
0	poly	0.01	0.682589
1	poly	0.05	0.679940
2	poly	0.10	0.689474
3	poly	0.50	0.699615
4	poly	1.00	0.704131
5	poly	5.00	0.712744
6	poly	10.00	0.706170
7	poly	20.00	0.715220
8	poly	50.00	0.715220
9	poly	200.00	0.719703
10	poly	100.00	0.715220

11	rbf	0.01	0.691813
12	rbf	0.05	0.773060
13	rbf	0.10	0.765152
14	rbf	0.50	0.772491
15	rbf	1.00	0.793899
16	rbf	5.00	0.792804
17	rbf	10.00	0.793194
18	rbf	20.00	0.792804
19	rbf	50.00	0.799804
20	rbf	200.00	0.796699
21	rbf	100.00	0.799804




για τον Polynomial πυρήνα παρατηρούμε ότι έχει την χαμηλότερη απόδοση, το F1 score έχει τις χαμηλότερες τιμές, ενώ για $c > 50$ φαίνεται ότι υπάρχει μια σταθερότητα αλλά και πάλι η μετρική είναι σε χαμηλά επίπεδα. Ο πυρήνας δεν αποδίδει τόσο καλά άρα τα δεδομένα δεν έχουν πολυωνυμική σχέση μεταξύ των χαρακτηριστικών τους.

Οπότε, οι τελικοί πυρήνες είναι γραμμικός και rbf


	Kernel	C	F1 Score
0	linear	0.01	0.725658
1	linear	0.05	0.715897
2	linear	0.10	0.715897
3	linear	0.50	0.719335
4	linear	1.00	0.715897
5	linear	5.00	0.715897
6	linear	10.00	0.715897
7	linear	20.00	0.715897
8	linear	50.00	0.715897
9	linear	100.00	0.715897
10	linear	200.00	0.715897

➡ Παρατηρούμε ότι για τον γραμμικό πυρήνα οι τιμές του F1-score παρουσιάζουν μια σταθερότητα μεταξύ των τιμών του c. Η απόδοση δεν βελτιώνεται γενικά άρα ίσως η σχέση των χαρακτηριστικών δεν είναι γραμμική.



11	rbf	0.01	0.691813
12	rbf	0.05	0.773060
13	rbf	0.10	0.765152
14	rbf	0.50	0.772491
15	rbf	1.00	0.793899
16	rbf	5.00	0.792804
17	rbf	10.00	0.793194
18	rbf	20.00	0.792804
19	rbf	50.00	0.799804
20	rbf	100.00	0.799804
21	rbf	200.00	0.796699

➡ Η τιμή του F1 Score για μικρές παρουσιάζει μια μεγάλη άνοδο απο $c=0.01$ σε 0.05 ενώ μετά η μετρική έχει μια μικρή αύξηση η οποία κορυφώνεται για $C = 50, 100, 200$. Συγκριτικά και με τους άλλους δυο πυρήνες είναι μη γραμμικό και για αυτό ο rbf διαχειρίζεται καλύτερα τα δεδομένα. Όμως το F1 score σταθεροποιείται γεγονός που δείχνει ότι το μοντέλο δεν βελτιώνεται παραπάνω.



Το τελικό συμπέρασμα συγκρίνοντας τα αποτελέσματα των παραπάνω μεθόδων ταξινόμησης και της μετρικής F1 score συγκεκριμένα είναι πως η καλύτερη μέθοδος είναι η k-NN ($k=5$), με F1 Score = 0.8611.

Η δεύτερη καλύτερη μέθοδος είναι τα Parzen Windows με Bandwidth = 0.10 (F1 = 0.8645).

Ο RBF SVM έχει μια σταθερότητα στα αποτελέσματα αλλά δεν είναι τόσο καλή η ταξινόμηση όσο το k-NN ή Parzen. ενώ ο Linear SVM έχει τη χειρότερη απόδοση και δεν είναι κατάλληλος για αυτό το dataset.